

BeliefMove: Bayesian Belief-Augmented Large Language Model Agents for Uncertainty-Aware Next GPS Point Prediction

Tóm tắt nội dung

Dự đoán điểm GPS kế tiếp là một bài toán quan trọng trong khai phá trajectory, phân tích hành vi di chuyển và hệ thống giao thông thông minh. Các mô hình học sâu truyền thống có khả năng khai thác phụ thuộc không-thời gian nhưng thường gặp khó khăn khi trajectory thưa, nhiễu hoặc có nhiều hướng di chuyển khả dĩ. Gần đây, Large Language Models, LLMs, và các mô hình tác tử dựa trên LLM mở ra một hướng tiếp cận mới cho bài toán dự đoán vị trí thông qua khả năng suy luận ngữ nghĩa, khai thác tri thức và mô hình hóa ý định di chuyển. Tuy nhiên, LLM thường đưa ra một kết quả dự đoán duy nhất và chưa biểu diễn một cách có cấu trúc sự bất định giữa nhiều giả thuyết di chuyển.

Bài nghiên cứu này đề xuất **BeliefMove**, một framework kết hợp LLM Agent với Bayesian Belief Network, BBN, cho dự đoán điểm GPS kế tiếp. Thay vì yêu cầu LLM trực tiếp dự đoán tọa độ kế tiếp, BeliefMove sử dụng LLM Agent để phân tích trajectory, suy luận ý định di chuyển và sinh ra một tập các giả thuyết về hướng hoặc tuyến đường tiếp theo. BBN sau đó chuyển các giả thuyết này thành một trạng thái belief xác suất và cập nhật trạng thái đó khi các quan sát GPS mới xuất hiện. Một cơ chế adaptive reasoning được đề xuất để cho phép Agent quyết định khi nào cần thực hiện thêm suy luận dựa trên entropy của belief state và mức độ bất đồng giữa LLM và BBN. Framework này hướng tới đồng thời cải thiện độ chính xác, khả năng chịu nhiễu, khả năng hiệu chỉnh xác suất và hiệu quả suy luận. Nghiên cứu được đánh giá trên nhiều tập dữ liệu GPS trajectory với các thí nghiệm về dự đoán điểm kế tiếp, dự đoán nhiều bước, dữ liệu thưa, nhiễu GPS, tổng quát hóa giữa các thành phố và calibration của độ tin cậy.

1 Giới thiệu

GPS trajectory cung cấp một nguồn dữ liệu quan trọng để nghiên cứu hành vi di chuyển của con người và phương tiện. Một trajectory có thể được biểu diễn dưới dạng chuỗi các quan sát:

$$\mathcal{T}_{1:t} = \{p_1, p_2, \dots, p_t\}, \quad (1)$$

trong đó mỗi điểm GPS được biểu diễn bởi:

$$p_i = (lat_i, lon_i, time_i). \quad (2)$$

Một bài toán cơ bản trong trajectory mining là dự đoán điểm GPS tiếp theo:

$$p_{t+1} = (lat_{t+1}, lon_{t+1}), \quad (3)$$

dựa trên lịch sử trajectory:

$$P(p_{t+1} \mid p_1, \dots, p_t). \quad (4)$$

Các mô hình truyền thống như Markov model, Hidden Markov Model, Recurrent Neural Network, LSTM và Transformer đã được sử dụng rộng rãi cho bài toán này. Tuy nhiên, các mô hình này thường tập trung vào việc học quan hệ thống kê giữa các điểm GPS và chưa khai thác

đầy đủ các yếu tố ngữ nghĩa như ý định di chuyển, mục tiêu chuyển đi, hoạt động của người dùng và tri thức về không gian.

Sự phát triển của Large Language Models tạo ra một hướng tiếp cận mới. LLM có khả năng biểu diễn và suy luận trên thông tin không gian-thời gian ở dạng ngôn ngữ. Các nghiên cứu gần đây về LLM-based mobility agents, trong đó có AgentMove, cho thấy việc sử dụng memory, world knowledge và agentic reasoning có thể cải thiện khả năng dự đoán vị trí kế tiếp.

Tuy nhiên, một hạn chế quan trọng vẫn tồn tại. Khi có nhiều hướng di chuyển khả dĩ, LLM thường phải lựa chọn một giả thuyết cuối cùng thay vì duy trì một phân phối xác suất trên các giả thuyết.

Giả sử tại vị trí hiện tại có ba khả năng:

$$H = \{H_1, H_2, H_3\}, \quad (5)$$

trong đó:

- H_1 : tiếp tục đi thẳng;
- H_2 : rẽ phải;
- H_3 : rẽ trái.

Một hệ thống dự đoán thông thường có thể lựa chọn:

$$\hat{H} = \arg \max_{H_i} P(H_i \mid \mathcal{T}_{1:t}). \quad (6)$$

Tuy nhiên, việc chỉ giữ lại một giả thuyết sẽ làm mất thông tin về bất định.

Nghiên cứu này đề xuất thay thế cách tiếp cận trên bằng một trạng thái belief:

$$B_t = \{P(H_1), P(H_2), \dots, P(H_K)\}. \quad (7)$$

Trạng thái belief được cập nhật liên tục khi quan sát mới xuất hiện:

$$B_t \rightarrow B_{t+1}. \quad (8)$$

Ý tưởng trung tâm của nghiên cứu là kết hợp ba khả năng:

$$\boxed{\text{LLM Reasoning} + \text{Bayesian Belief} + \text{Agentic Decision Making}} \quad (9)$$

Trong đó LLM chịu trách nhiệm suy luận ngữ nghĩa và sinh giả thuyết, Bayesian Belief Network định lượng và cập nhật bất định, còn Agent quyết định khi nào cần suy luận thêm.

2 Động lực nghiên cứu

2.1 Hạn chế của dự đoán tất định

Một mô hình dự đoán thông thường có dạng:

$$\hat{p}_{t+1} = f(p_1, \dots, p_t). \quad (10)$$

Cách biểu diễn này ngầm giả định rằng có một kết quả tối ưu duy nhất. Tuy nhiên, mobility trajectory thường có tính đa phương thức.

Từ cùng một vị trí, phương tiện có thể:

$$P(p_{t+1} \mid \mathcal{T}) = \sum_{k=1}^K P(p_{t+1} \mid H_k, \mathcal{T}) P(H_k \mid \mathcal{T}). \quad (11)$$

Do đó, việc mô hình hóa phân phối trên các giả thuyết là phù hợp hơn với bản chất của bài toán.

2.2 LLM có khả năng reasoning nhưng chưa có belief state rõ ràng

LLM có thể suy luận rằng một trajectory có khả năng tương ứng với hành trình đi làm:

$$P(Intent = commuting | \mathcal{T}) \approx 0.72. \quad (12)$$

Tuy nhiên, confidence do LLM sinh ra không nhất thiết là một xác suất được hiệu chỉnh tốt. Vì vậy, nghiên cứu đề xuất tách hai vai trò:

$$LLM \rightarrow \text{Semantic Hypothesis} \quad (13)$$

và:

$$BBN \rightarrow \text{Probabilistic Belief}. \quad (14)$$

2.3 Động lực cho adaptive reasoning

Không phải mọi trajectory đều cần nhiều bước suy luận.

Nếu:

$$H(B_t) = - \sum_i P(H_i) \log P(H_i) \quad (15)$$

nhỏ, Agent có thể trực tiếp dự đoán.

Ngược lại, nếu:

$$H(B_t) > \tau, \quad (16)$$

Agent cần thực hiện thêm reasoning hoặc khai thác thêm context.

Điều này cho phép giảm chi phí gọi LLM trong các trường hợp prediction đã có độ tin cậy cao.

3 Khoảng trống nghiên cứu

Nghiên cứu đề xuất tập trung vào bốn khoảng trống chính.

1. Các mô hình LLM-based mobility reasoning có khả năng suy luận ngữ nghĩa nhưng chưa khai thác đầy đủ một belief state xác suất có thể cập nhật theo thời gian.
2. Các mô hình Bayesian truyền thống có khả năng biểu diễn bất định nhưng khó khai thác world knowledge và semantic mobility intent ở mức cao.
3. Hai loại reasoning trên thường được nghiên cứu riêng biệt thay vì kết hợp trong một agentic framework.
4. Chi phí suy luận của LLM có thể cao nếu Agent luôn thực hiện nhiều bước reasoning, trong khi không phải mọi trạng thái trajectory đều có mức độ bất định cao.

Từ đó, nghiên cứu đặt ra câu hỏi:

Liệu việc kết hợp semantic reasoning của LLM với Bayesian belief reasoning và adaptive agentic decision making có thể cải thiện độ chính xác, độ tin cậy và khả năng chống chịu của dự đoán điểm GPS kế tiếp hay không?

4 Mục tiêu nghiên cứu

Mục tiêu tổng quát là xây dựng một framework LLM Agent có khả năng dự đoán điểm GPS kế tiếp trong điều kiện bất định.

Các mục tiêu cụ thể gồm:

1. Xây dựng biểu diễn trajectory phù hợp cho LLM-based mobility reasoning.
2. Thiết kế Mobility Belief Network biểu diễn các biến ẩn như mobility intent, destination và next road.
3. Thiết kế cơ chế để LLM Agent sinh các mobility hypotheses.
4. Thiết kế Bayesian belief updating khi quan sát GPS mới.
5. Thiết kế cơ chế adaptive reasoning dựa trên uncertainty.
6. Đánh giá khả năng dự đoán trong điều kiện GPS thưa và nhiễu.
7. Đánh giá uncertainty calibration.
8. Đánh giá khả năng giảm chi phí suy luận LLM.

5 Câu hỏi nghiên cứu

5.1 RQ1

Liệu Bayesian belief reasoning có cải thiện độ chính xác dự đoán điểm GPS kế tiếp so với LLM Agent thuần túy hay không?

5.2 RQ2

Liệu belief updating có giúp mô hình chống chịu tốt hơn với GPS bị thiếu hoặc nhiễu hay không?

5.3 RQ3

Liệu Bayesian belief có giúp confidence của mô hình được calibration tốt hơn hay không?

5.4 RQ4

Liệu adaptive reasoning có thể giảm số lần gọi LLM mà không làm giảm đáng kể độ chính xác hay không?

6 Framework BeliefMove


6.1 Tổng quan

Framework đề xuất có sáu thành phần:

1. GPS trajectory parser;
2. Spatial-temporal trajectory encoder;
3. LLM Mobility Agent;
4. Mobility Hypothesis Generator;

5. Bayesian Belief Network;
6. Adaptive Reasoning Controller.

Kiến trúc tổng quát được mô tả trong Hình 1.



Hình 1: Kiến trúc tổng thể của BeliefMove.

7 Biểu diễn bài toán

Cho trajectory:

$$\mathcal{T}_{1:t} = \{p_1, p_2, \dots, p_t\}. \quad (17)$$

Mỗi điểm:

$$p_i = (lat_i, lon_i, time_i, v_i, h_i), \quad (18)$$

trong đó:

- lat_i : latitude;

- lon_i : longitude;
- $time_i$: timestamp;
- v_i : tốc độ;
- h_i : hướng di chuyển.

Ngoài trajectory, hệ thống có thể sử dụng context:

$$C_t = \{road_t, region_t, POI_t, traffic_t, weather_t\}. \quad (19)$$

Mục tiêu là học:

$$P(p_{t+1} \mid \mathcal{T}_{1:t}, C_t). \quad (20)$$

8 Mobility State

Thay vì đưa trực tiếp latitude và longitude vào BBN, nghiên cứu định nghĩa một mobility state:

$$S_t = \{R_t, A_t, I_t, D_t, V_t, H_t\}, \quad (21)$$

trong đó:

- R_t : road segment;
- A_t : activity;
- I_t : mobility intent;
- D_t : destination;
- V_t : speed state;
- H_t : heading state.

Điểm GPS kế tiếp được suy ra từ mobility state:

$$P(p_{t+1} \mid \mathcal{T}_{1:t}) = \sum_{S_t} P(p_{t+1} \mid S_t) P(S_t \mid \mathcal{T}_{1:t}). \quad (22)$$

9 LLM Mobility Agent

LLM Agent nhận trajectory đã được chuẩn hóa thành một biểu diễn có ý nghĩa:

```
time = 08:10
road = R125
speed = 31 km/h
heading = East
region = District_1
```

```
time = 08:11
road = R126
speed = 34 km/h
heading = East
region = District_1
```

Agent thực hiện ba nhiệm vụ.

9.1 Trajectory interpretation

Agent phân tích:

$$Z_t = f_{\text{LLM}}(\mathcal{T}_{1:t}, C_t). \quad (23)$$

9.2 Intent inference

Agent suy luận:

$$P_{\text{LLM}}(I_t \mid Z_t). \quad (24)$$

Ví dụ:

```
commuting = 0.72
shopping  = 0.18
other     = 0.10
```

9.3 Hypothesis generation

Agent sinh:

$$\mathcal{H}_t = \{H_1, H_2, \dots, H_K\}. \quad (25)$$

Mỗi hypothesis có thể chứa:


$$H_k = (intent, destination, next_road, next_region). \quad (26)$$

10 Mobility Bayesian Belief Network

10.1 Mục tiêu

BBN được sử dụng để mô hình hóa quan hệ xác suất giữa các biến mobility.

Một mạng đề xuất:



Hình 2: Mobility Bayesian Belief Network.

Các quan hệ xác suất chính gồm:

$$P(I_t \mid History, Time, Activity, POI), \quad (27)$$

$$P(D_t \mid I_t, History), \quad (28)$$

$$P(R_{t+1} \mid R_t, H_t, D_t), \quad (29)$$

và:

$$P(p_{t+1} \mid R_{t+1}, V_t, H_t). \quad (30)$$

11 Bayesian Belief Updating

Tại thời điểm t , Agent duy trì belief:

$$B_t(H_i) = P(H_i \mid E_{1:t}), \quad (31)$$

trong đó $E_{1:t}$ là toàn bộ evidence đã quan sát.

Khi GPS mới E_{t+1} xuất hiện:

$$B_{t+1}(H_i) = P(H_i \mid E_{1:t+1}). \quad (32)$$

Theo Bayes:

$$B_{t+1}(H_i) = \frac{P(E_{t+1} \mid H_i) B_t(H_i)}{\sum_{j=1}^K P(E_{t+1} \mid H_j) B_t(H_j)}. \quad (33)$$

Ví dụ ban đầu:

$$B_t = \{0.50, 0.30, 0.20\}. \quad (34)$$

Sau quan sát mới:

$$B_{t+1} = \{0.68, 0.22, 0.10\}. \quad (35)$$

Belief state vì vậy được cập nhật thay vì tái khởi tạo sau mỗi quan sát.

12 LLM–BBN Belief Fusion

LLM tạo:

$$P_{LLM}(H_i). \quad (36)$$

BBN tạo:

$$P_{BBN}(H_i). \quad (37)$$

Một baseline fusion đơn giản là:

$$P^*(H_i) = \alpha P_{LLM}(H_i) + (1 - \alpha) P_{BBN}(H_i). \quad (38)$$

Tuy nhiên, nghiên cứu đề xuất sử dụng trọng số thích nghi:

$$\alpha_t = f(U_{LLM}, U_{BBN}, D_{LLM, BBN}), \quad (39)$$

trong đó:

$$U_{LLM} \quad (40)$$

là uncertainty của LLM,

$$U_{BBN} \quad (41)$$

là uncertainty của BBN, và:

$$D_{LLM, BBN} = D_{KL}(P_{LLM} \parallel P_{BBN}) \quad (42)$$

đo mức độ bất đồng giữa hai nguồn reasoning.

Belief cuối cùng:

$$P^*(H_i) = \alpha_t P_{LLM}(H_i) + (1 - \alpha_t) P_{BBN}(H_i). \quad (43)$$

13 Belief Memory

Một thành phần mới được đề xuất là **Bayesian Belief Memory**.

Thay vì chỉ lưu text hoặc historical trajectory, Agent lưu:

$$M_t^B = \{B_1, B_2, \dots, B_t\}. \quad (44)$$

Mỗi belief state:

$$B_t = \{P(I_t), P(D_t), P(R_{t+1}), P(Region_{t+1})\}. \quad (45)$$

Belief Memory cho phép Agent truy hồi các trạng thái bất định trước đó và cập nhật chúng khi trajectory mới xuất hiện.

14 Adaptive Uncertainty-Aware Reasoning

Entropy của belief được định nghĩa:

$$\mathcal{H}(B_t) = - \sum_{i=1}^K P(H_i) \log P(H_i). \quad (46)$$

Nếu:

$$\mathcal{H}(B_t) < \tau, \quad (47)$$

Agent thực hiện prediction.

Nếu:

$$\mathcal{H}(B_t) \geq \tau, \quad (48)$$

Agent thực hiện additional reasoning.

Một policy đơn giản:

$$a_t = \begin{cases} predict, & \mathcal{H}(B_t) < \tau \\ reason, & \mathcal{H}(B_t) \geq \tau. \end{cases} \quad (49)$$

Một policy mở rộng có thể sử dụng:

$$a_t = \pi(B_t, \mathcal{H}(B_t), D_{LLM, BBN}, C_t). \quad (50)$$

Các action có thể gồm:

$$a_t \in \{predict, retrieve, reason, update, observe\}. \quad (51)$$

15 Dự đoán điểm GPS kế tiếp

Sau khi có belief:

$$P(R_{t+1} \mid E_{1:t}), \quad (52)$$

mô hình dự đoán GPS:

$$P(p_{t+1} \mid R_{t+1}, V_t, H_t, B_t). \quad (53)$$

Điểm dự đoán có thể được tính:

$$\hat{p}_{t+1} = \sum_r P(R_{t+1} = r \mid B_t) \hat{p}_{t+1}^{(r)}. \quad (54)$$

Trong trường hợp multi-modal prediction:

$$\mathcal{P}_{t+1} = \{(\hat{p}_{t+1}^{(1)}, q_1), \dots, (\hat{p}_{t+1}^{(K)}, q_K)\}. \quad (55)$$

Trong đó q_i là xác suất của hypothesis tương ứng.

16 Multi-step Trajectory Forecasting

Framework có thể được mở rộng từ next-point prediction sang multi-step forecasting:

$$\hat{\mathcal{T}}_{t+1:t+K} = \{\hat{p}_{t+1}, \dots, \hat{p}_{t+K}\}. \quad (56)$$

Sau mỗi bước, belief được cập nhật:

$$B_t \rightarrow B_{t+1} \rightarrow \dots \rightarrow B_{t+K}. \quad (57)$$

Do đó framework không chỉ dự đoán một điểm độc lập mà thực hiện sequential probabilistic forecasting.

17 Thuật toán BeliefMove

Algorithm 1 BeliefMove: Bayesian Belief-Augmented Mobility Agent

Require: Trajectory $\mathcal{T}_{1:t}$, context C_t , belief state B_t , uncertainty threshold τ

Ensure: Next GPS prediction $\hat{p}_{t+1}$

```

1:  $Z_t \leftarrow \text{Encode}(\mathcal{T}_{1:t}, C_t)$ 
2:  $S_t \leftarrow \text{LLMReason}(Z_t)$ 
3:  $\mathcal{H}_t \leftarrow \text{GenerateHypotheses}(S_t)$ 
4:  $P_{LLM} \leftarrow \text{EstimateLLMBelief}(\mathcal{H}_t)$ 
5:  $P_{BBN} \leftarrow \text{BayesianInference}(B_t, S_t)$ 
6:  $D \leftarrow D_{KL}(P_{LLM} \| P_{BBN})$ 
7:  $B_t \leftarrow \text{AdaptiveFusion}(P_{LLM}, P_{BBN}, D)$ 
8:  $U \leftarrow \text{Entropy}(B_t)$ 
9: if  $U \geq \tau$  then
10:    $C'_t \leftarrow \text{RetrieveAdditionalContext}(C_t)$ 
11:    $S'_t \leftarrow \text{AdditionalReasoning}(Z_t, C'_t)$ 
12:    $B_t \leftarrow \text{UpdateBelief}(B_t, S'_t)$ 
13: end if
14:  $\hat{p}_{t+1} \leftarrow \text{GPSDecoder}(B_t)$ 
15:  $B_{t+1} \leftarrow \text{BeliefUpdate}(B_t, \hat{p}_{t+1})$ 
16: return  $\hat{p}_{t+1}$ 

```

18 Thiết kế thực nghiệm

18.1 Dataset

Nghiên cứu đề xuất sử dụng ít nhất ba tập dữ liệu:

- GeoLife;

- T-Drive;
- Porto Taxi.

Các dataset này đại diện cho các dạng mobility khác nhau, bao gồm human mobility và vehicle mobility.

18.2 Tiền xử lý

Pipeline:

$$Raw\ GPS \rightarrow Cleaning \rightarrow Segmentation \rightarrow Map\ Matching \rightarrow Spatial\ Representation \rightarrow Trajectory\ Sequences \quad (58)$$

Các bước gồm:

1. Sắp xếp dữ liệu theo user hoặc vehicle và timestamp.
2. Loại bỏ các điểm GPS không hợp lệ.
3. Tính tốc độ:

$$v_i = \frac{d(p_i, p_{i-1})}{t_i - t_{i-1}}. \quad (59)$$

4. Loại bỏ hoặc đánh dấu các điểm có tốc độ bất thường.
5. Map matching sang road segment nếu bản đồ đường được sử dụng.
6. Chuyển trajectory thành các cửa sổ quan sát.

19 Các baseline

Các baseline được chia thành bốn nhóm.

19.1 Traditional models

1. Historical Average;
2. Markov Model;
3. Kalman Filter.

19.2 Deep learning models

1. LSTM;
2. GRU;
3. Transformer.

19.3 LLM-based models

1. Direct LLM;
2. AgentMove;
3. Các LLM-based trajectory models phù hợp.

19.4 Proposed models

1. AgentMove + BBN;
2. AgentMove + Intent + BBN;
3. BeliefMove;
4. BeliefMove + Adaptive Reasoning.

20 Ablation Study

Ablation study gồm:

Bảng 1: Các phiên bản ablation của framework.

Model	LLM	Agent	Intent	BBN	Adaptive
Transformer					
LLM	✓				
AgentMove	✓	✓	✓		
AgentMove-BBN	✓	✓		✓	
AgentMove-Intent-BBN	✓	✓	✓	✓	
BeliefMove	✓	✓	✓	✓	✓

Mục tiêu của ablation là xác định đóng góp độc lập của từng thành phần.

21 Metrics

21.1 Average Displacement Error

$$ADE = \frac{1}{N} \sum_{i=1}^N d(p_i, \hat{p}_i). \quad (60)$$

21.2 Final Displacement Error

$$FDE = d(p_T, \hat{p}_T). \quad (61)$$

21.3 Haversine Distance

Khoảng cách địa lý được tính bằng công thức Haversine.

$$d = 2R \arcsin \left(\sqrt{\sin^2 \frac{\Delta\phi}{2} + \cos(\phi_1) \cos(\phi_2) \sin^2 \frac{\Delta\lambda}{2}} \right). \quad (62)$$

21.4 Top- K Accuracy

$$Accuracy@K = \frac{\text{Number of correct predictions within top-}K}{N}. \quad (63)$$

22 Uncertainty Calibration

Do framework sinh ra probability distribution, cần đánh giá calibration.

22.1 Negative Log-Likelihood

$$NLL = -\frac{1}{N} \sum_{i=1}^N \log P(y_i | x_i). \quad (64)$$

22.2 Brier Score

$$BS = \frac{1}{N} \sum_{i=1}^N (p_i - y_i)^2. \quad (65)$$

22.3 Expected Calibration Error

$$ECE = \sum_{m=1}^M \frac{|B_m|}{N} |acc(B_m) - conf(B_m)|. \quad (66)$$

23 Thí nghiệm với GPS bị thiếu

Để đánh giá robustness, ngẫu nhiên loại bỏ một tỷ lệ GPS points:

$$r \in \{0, 0.1, 0.2, 0.3, 0.5\}. \quad (67)$$

So sánh:

$$ADE(r), FDE(r). \quad (68)$$

Giả thuyết:

$$\left. \frac{\partial ADE}{\partial r} \right|_{\text{BeliefMove}} < \left. \frac{\partial ADE}{\partial r} \right|_{\text{AgentMove}}. \quad (69)$$

Điều này cho thấy belief state giúp mô hình duy trì thông tin khi quan sát bị thiếu.

24 Thí nghiệm với GPS nhiễu

GPS noise được mô hình hóa:

$$p'_i = p_i + \epsilon_i, \quad (70)$$

trong đó:

$$\epsilon_i \sim \mathcal{N}(0, \sigma^2). \quad (71)$$

Thử nghiệm với:

$$\sigma \in \{5m, 10m, 20m, 50m, 100m\}. \quad (72)$$

25 Cross-City Generalization

Mô hình được train trên một thành phố và test trên thành phố khác.

Ví dụ:

$$Train = Beijing, \quad Test = Porto. \quad (73)$$

Đánh giá:

$$\Delta ADE = ADE_{cross-city} - ADE_{in-city}. \quad (74)$$

Một mô hình tổng quát tốt nên có:

$$\Delta ADE \rightarrow 0. \quad (75)$$

26 LLM Cost Analysis

Đánh giá:

$$Cost = f(N_{calls}, N_{tokens}, Latency). \quad (76)$$

So sánh:

Bảng 2: Đánh giá hiệu quả suy luận.				
Model	LLM Calls	Tokens	Latency	ADE
LLM				
AgentMove				
AgentMove-BBN				
BeliefMove				

Mục tiêu là chứng minh:

$$Cost_{BeliefMove} < Cost_{AgentMove} \quad (77)$$

trong khi:

$$ADE_{BeliefMove} \leq ADE_{AgentMove}. \quad (78)$$

27 Nghiên cứu sự bất đồng giữa LLM và BBN

Định nghĩa:

$$D_t = D_{KL}(P_{LLM} \| P_{BBN}). \quad (79)$$

Nếu:

$$D_t > \delta, \quad (80)$$

Agent thực hiện reflection.

Quy trình:

$$LLM \rightarrow BBN \rightarrow Disagreement \rightarrow Reflection \rightarrow Belief Update. \quad (81)$$

Đây là một thí nghiệm quan trọng để chứng minh Agent không chỉ là một pipeline tuần tự mà có khả năng tự điều chỉnh reasoning.

28 Các giả thuyết nghiên cứu

28.1 H1

BeliefMove có ADE và FDE thấp hơn AgentMove.

$$ADE_{BeliefMove} < ADE_{AgentMove}. \quad (82)$$

28.2 H2

BeliefMove có robustness tốt hơn khi GPS bị thiếu.

$$ADE_{BeliefMove}(r) < ADE_{AgentMove}(r). \quad (83)$$

28.3 H3

BeliefMove có calibration tốt hơn.

$$ECE_{BeliefMove} < ECE_{AgentMove}. \quad (84)$$

28.4 H4

Adaptive reasoning giảm chi phí LLM.

$$Calls_{Adaptive} < Calls_{FullReasoning}. \quad (85)$$

29 Các đóng góp dự kiến

Nghiên cứu dự kiến có bốn đóng góp chính.

1. Đề xuất BeliefMove, một framework kết hợp LLM Agent và Bayesian Belief Network cho dự đoán điểm GPS kế tiếp theo hướng probabilistic mobility reasoning.
2. Đề xuất Mobility Belief Network biểu diễn có cấu trúc các biến ẩn gồm mobility intent, destination, next road và next region.
3. Đề xuất Bayesian Belief Memory và adaptive belief updating để duy trì và cập nhật nhiều mobility hypotheses trong quá trình trajectory tiếp diễn.
4. Đề xuất adaptive uncertainty-aware reasoning dựa trên entropy và LLM-BBN disagreement nhằm cân bằng prediction accuracy và LLM inference cost.

30 Kế hoạch thực nghiệm

Nghiên cứu được triển khai theo các giai đoạn sau.

Bảng 3: Lộ trình thực nghiệm.

Giai đoạn	Nội dung	Kết quả
1	Reproduce AgentMove	Baseline
2	GPS preprocessing	GPS benchmark
3	Traditional baselines	Baseline results
4	LLM baseline	LLM results
5	AgentMove-GPS	Agent baseline
6	Standalone BBN	BBN baseline
7	LLM + BBN	Initial proposed model
8	Belief Memory	Sequential belief model
9	Adaptive reasoning	Final model
10	Robustness	Noise and missing GPS
11	Calibration	Uncertainty evaluation
12	Cross-city	Generalization
13	Cost analysis	Efficiency evaluation
14	Case studies	Qualitative analysis

31 Thiết kế thí nghiệm tổng thể

Một benchmark hoàn chỉnh có thể được tổ chức như sau:

$$Datasets \times Models \times Noise \times MissingRate \times Seeds. \quad (86)$$

Trong đó:

$$Datasets = \{GeoLife, T-Drive, Porto\}, \quad (87)$$

$$Models = \{LSTM, Transformer, LLM, AgentMove, AgentMove-BBN, BeliefMove\}. \quad (88)$$

32 Phân tích trường hợp điển hình

Một trajectory có thể có dạng:

$$P_1 \rightarrow P_2 \rightarrow P_3 \rightarrow P_4. \quad (89)$$

Tại P_4 , Agent sinh:

$$P_{LLM} = \{Road_A : 0.72, Road_B : 0.18, Road_C : 0.10\}. \quad (90)$$

Trong khi BBN có:

$$P_{BBN} = \{Road_A : 0.41, Road_B : 0.49, Road_C : 0.10\}. \quad (91)$$

Mức độ bất đồng được tính:

$$D_{KL} = D_{KL}(P_{LLM} \| P_{BBN}). \quad (92)$$

Nếu mức độ bất đồng cao, Agent kích hoạt thêm reasoning.

Sau khi có thêm context:

$$P^* = \{Road_A : 0.56, Road_B : 0.34, Road_C : 0.10\}. \quad (93)$$

Điểm GPS tiếp theo được sinh từ belief cuối cùng.

33 Định hướng mở rộng

Framework có thể được mở rộng theo bốn hướng.

33.1 Multi-step forecasting

$$p_{t+1:t+K}. \quad (94)$$

33.2 Destination prediction

Thay vì chỉ dự đoán điểm kế tiếp:

$$P(\textit{Destination} \mid \mathcal{T}). \quad (95)$$

33.3 Trajectory generation

Sinh toàn bộ trajectory có xác suất:

$$P(p_{t+1}, \dots, p_{t+K} \mid \mathcal{T}_{1:t}). \quad (96)$$

33.4 Real-time mobility agent

Agent có thể liên tục nhận GPS stream:

$$GPS_t \rightarrow Belief_t \rightarrow Prediction_t \rightarrow GPS_{t+1} \rightarrow Belief_{t+1}. \quad (97)$$

Điều này mở ra khả năng ứng dụng trong Intelligent Transportation Systems.

34 Kết luận

Nghiên cứu đề xuất BeliefMove, một framework kết hợp Large Language Model Agent, Bayesian Belief Network và adaptive reasoning cho bài toán dự đoán điểm GPS kế tiếp. Ý tưởng trung tâm là chuyển bài toán từ deterministic next-point prediction sang probabilistic agentic mobility reasoning.

Trong framework đề xuất, LLM không trực tiếp quyết định một điểm GPS duy nhất mà đóng vai trò semantic reasoner, phân tích trajectory, suy luận mobility intent và sinh các giả thuyết di chuyển. Bayesian Belief Network đóng vai trò probabilistic reasoner, định lượng xác suất của các giả thuyết và cập nhật belief khi quan sát mới xuất hiện. Agent đóng vai trò decision maker, sử dụng uncertainty và disagreement để quyết định khi nào cần thực hiện thêm reasoning.

Mô hình vì vậy được xây dựng dựa trên ba nguyên lý:

$$\boxed{\textit{Semantic Reasoning} + \textit{Probabilistic Belief} + \textit{Adaptive Decision}} \quad (98)$$

Khung nghiên cứu này không chỉ hướng tới cải thiện ADE hoặc FDE mà còn đặt trọng tâm vào robustness, uncertainty calibration, cross-city generalization và inference efficiency. Đây là các yếu tố cần thiết để LLM-based trajectory prediction có thể tiến từ một mô hình dự đoán vị trí sang một hệ thống agentic mobility intelligence có khả năng suy luận và ra quyết định dưới điều kiện bất định.